

FIAP

ESTUDO **TEACHABLE MACHINE**





INTRODUÇÃO AO ESTUDO

O avanço da inteligência artificial tem permitido a criação de soluções eficientes para a automação de tarefas do cotidiano. Uma dessas soluções é a classificação de imagens, que utiliza modelos treinados para identificar e categorizar objetos em tempo real. Neste estudo, foi desenvolvido um modelo de classificação de utensílios de cozinha utilizando a plataforma Teachable Machine, do Google.

O objetivo principal deste projeto é explorar e aplicar conceitos de aprendizado de máquina para reconhecer diferentes tipos de utensílios com base em suas características visuais. Para isso, foi realizado um processo estruturado envolvendo a coleta de imagens, o treinamento do modelo e a avaliação de sua precisão e acurácia.

Além de apresentar as etapas técnicas, este relatório detalha os desafios enfrentados, as métricas obtidas e possíveis melhorias para aprimorar o desempenho do modelo. A aplicação prática desse estudo pode ser útil em sistemas automatizados de reconhecimento de objetos em ambientes domésticos ou comerciais, contribuindo para o desenvolvimento de soluções inteligentes e acessíveis.



DADOS PARA TREINAMENTO

DETALHAMENTO DO CONJUNTO DE DADOS E PARÂMETROS DO MODELO

TOTAL DE IMAGENS

220 IMAGENS

CATEGORIAS

- Talheres: 50 IMG
- Tabuas de corte: 70 IMG
- Funil de cozinha: 50IMG
- Panelas: 50 IMG

MÉTRICAS

Épocas: 50
Batch size: 16
Learning rate: 0.001 (1e-3)

Para a construção do modelo de classificação de utensílios de cozinha, foram coletadas e organizadas imagens em quatro categorias distintas. O conjunto de dados foi balanceado para garantir que o modelo tivesse representatividade em todas as classes.

DETALHES DO TREINAMENTO

Justificativa das Configurações Escolhidas

1.Épocas: 50

Escolhemos 50 épocas porque queríamos que o modelo tivesse mais tempo para aprender e ajustar seus parâmetros com mais precisão. Um número maior de épocas permite que o modelo analise os dados várias vezes, o que ajuda a identificar padrões mais detalhados. Como o objetivo do treinamento era fazer a IA reconhecer vários objetos em um único cenário, incluindo o fundo e outros elementos, um treinamento mais longo ajuda o modelo a se tornar mais preciso.

2.Batch Size: 16

Optamos por um batch size de 16 porque ele oferece um bom equilíbrio entre o tempo de treinamento e a precisão. Lotes menores, como 16, atualizam os parâmetros do modelo com mais frequência, o que ajuda a capturar melhor as diferenças entre os objetos. Isso é importante em um cenário mais complexo, onde a IA precisa identificar não só os objetos principais, mas também outros detalhes do ambiente.



DETALHES DO TREINAMENTO

Justificativa das Configurações Escolhidas

3.Learning Rate: 0.001 (1e-3)

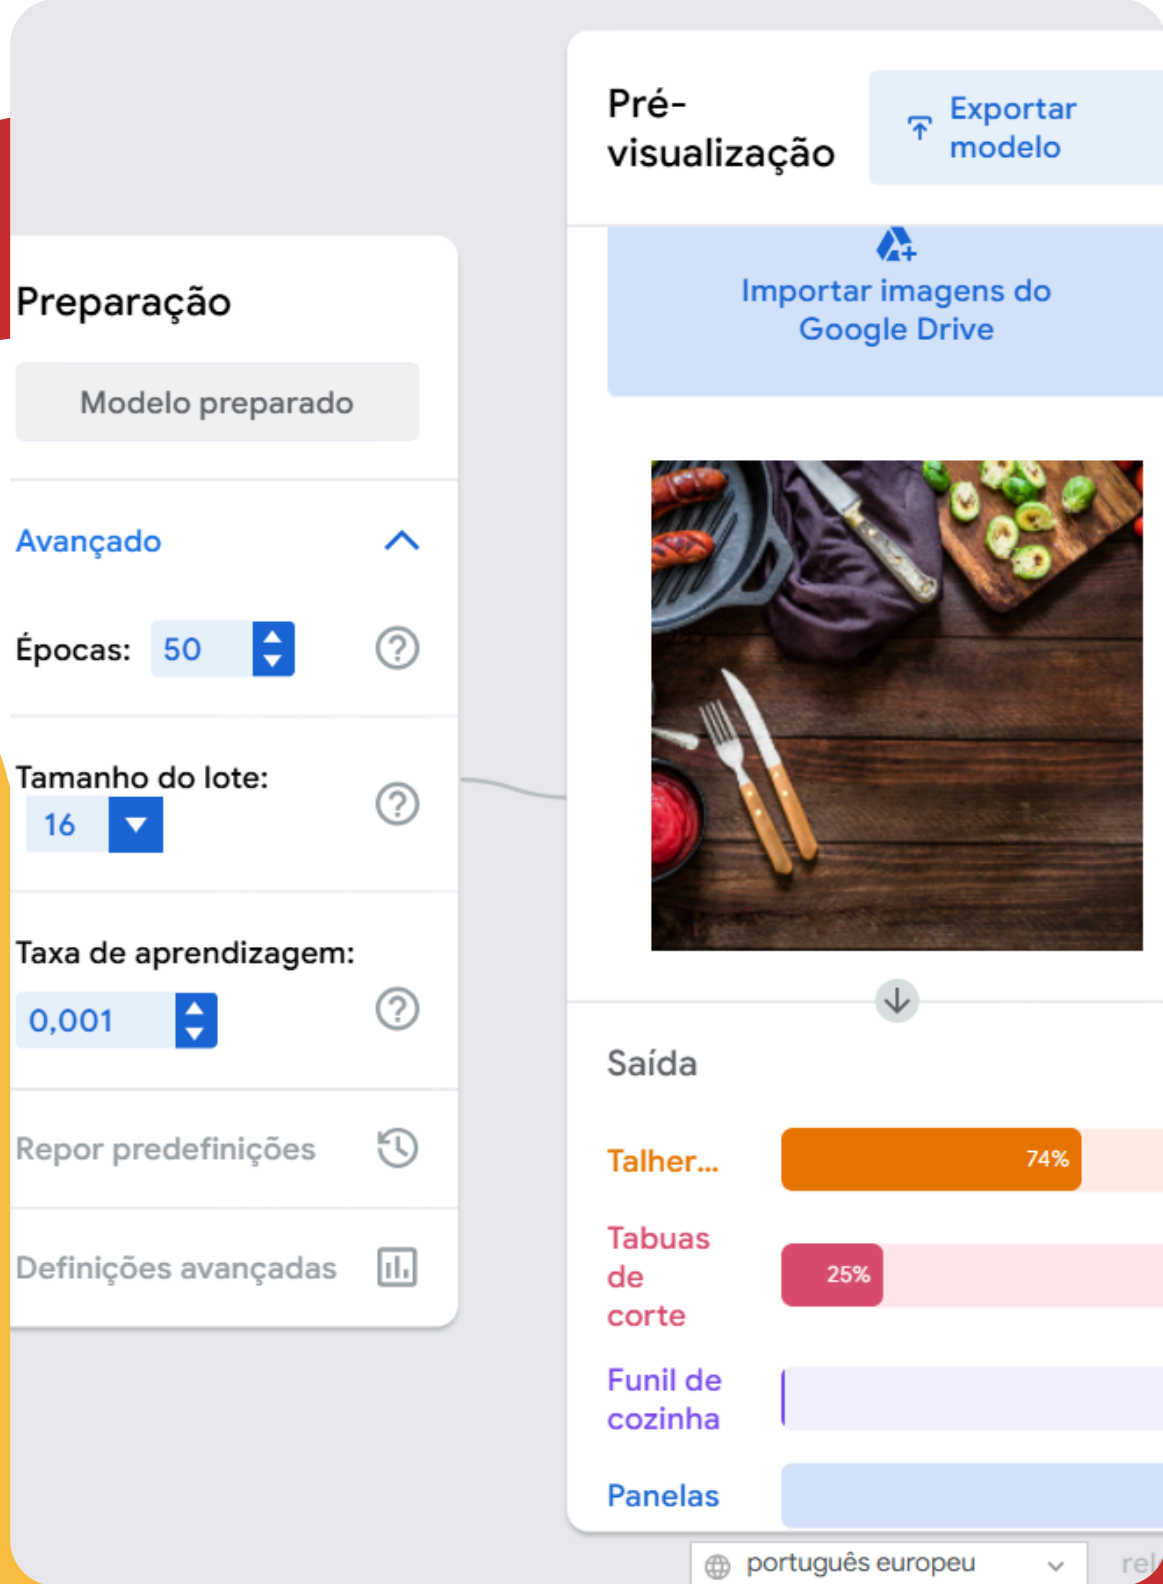
A taxa de aprendizado de 0.001 foi escolhida porque ela permite que o modelo aprenda de forma gradual e estável. Se usássemos um valor maior, o modelo poderia "pular" soluções importantes e não aprender direito. Por outro lado, um valor muito pequeno deixaria o treinamento muito demorado. Esse valor foi adequado porque o foco era garantir que a IA reconhecesse com mais precisão vários objetos e seus contextos, sem perder informações importantes do cenário.

Objetivo do Treinamento:

Nosso principal objetivo com o treinamento foi fazer com que a IA conseguisse identificar vários objetos em um mesmo ambiente de forma mais precisa. Não queríamos que ela reconhecesse apenas os objetos principais, mas também entendesse o fundo e outros detalhes do cenário. Por isso, priorizamos uma configuração que focasse na precisão do modelo, mesmo que isso deixasse o processo de treinamento um pouco mais demorado.



ANALISANDO O TESTE



1. Talher – 74%

Esse valor indica que o modelo tem alta confiança de que a imagem contém um talher. Considerando que essa categoria teve a maior porcentagem, o modelo provavelmente reconheceu características visuais fortes associadas a talheres, como formato metálico e contornos específicos.

✓ Interpretação:

O modelo está bem treinado para reconhecer talheres, mas a precisão ainda não está em 100%, o que sugere que há algumas incertezas ou sobreposição de características com outras categorias.

2. Tábua – 25%

A tábua foi reconhecida com uma confiança moderada. Isso indica que o modelo identificou alguns traços que correspondem a essa categoria, mas ainda há dificuldade em diferenciar a tábua de outros objetos.

⚠ Possíveis causas do erro:

- Semelhança visual: Se a tábua tem cores neutras (como madeira) ou um formato simples, pode ser confundida com outros objetos.
- Falta de exemplos: Talvez o modelo não tenha recebido imagens suficientes de tábuas em diferentes posições, iluminações ou materiais.

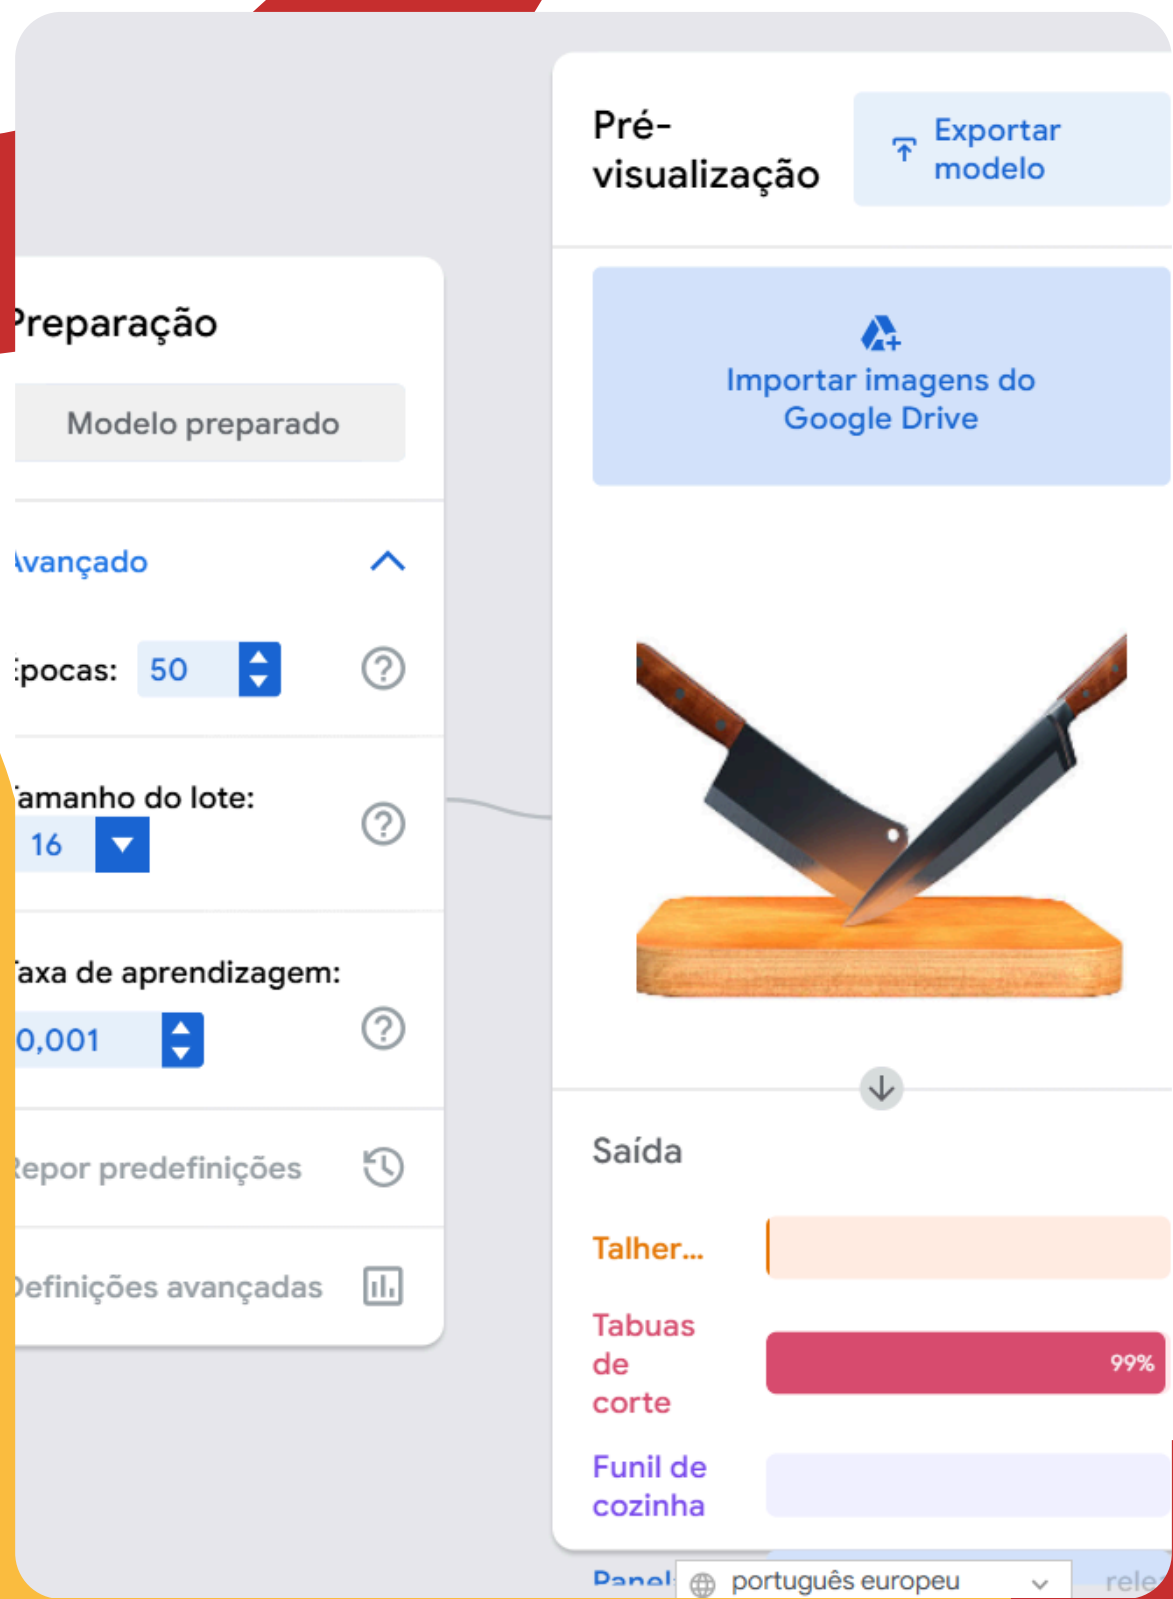
3. Funil – 1%

O reconhecimento de funil com baixa confiança indica que o modelo teve dúvidas e encontrou características que, em raros casos, se assemelham a um funil.

⚠ Por que isso acontece?

- Ruído no modelo: Pequenos detalhes na imagem (como sombras ou bordas arredondadas) podem confundir o algoritmo.
- Sobreposição de classes: Se as classes foram treinadas com imagens visualmente parecidas, o modelo pode fazer pequenas associações erradas.

ANALISANDO O TESTE



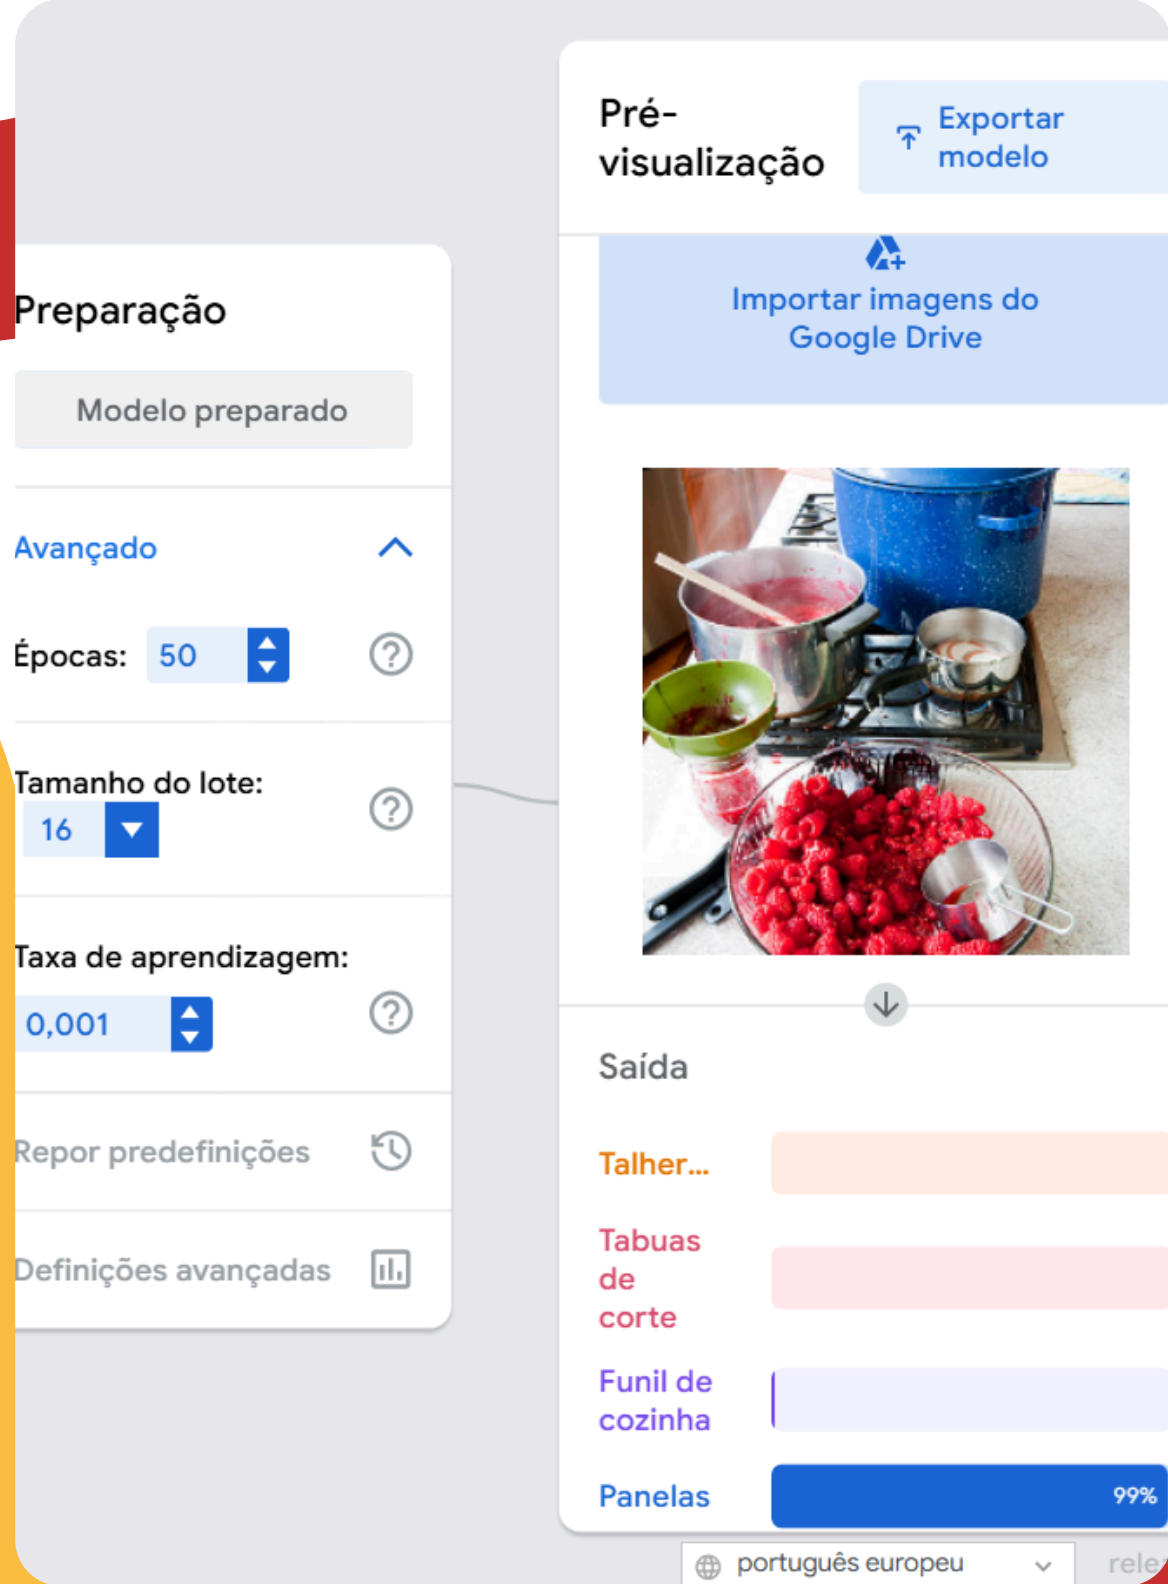
1.Tábua – 99%
Esse valor indica que o modelo tem alta confiança de que a imagem contém uma tábua. A precisão quase total sugere que o modelo reconheceu características visuais claras associadas a esse objeto, como formato plano e textura típica de madeira ou plástico.

✅ **Interpretação:**
O modelo está bem treinado para identificar tábuas, demonstrando que ele aprendeu a reconhecer esse objeto com precisão em diferentes cenários. A alta taxa de acerto mostra que essa categoria foi bem representada durante o treinamento.

2.Talher – 1%
Embora a imagem não contenha talheres, o modelo identificou essa categoria com uma baixa confiança (1%). Esse pequeno erro indica que o modelo encontrou algumas semelhanças entre o cutelo e os talheres, o que gerou um leve grau de incerteza.

- ⚠️ **Possíveis causas do erro:**
- **Similaridade visual:** O cutelo, por ter uma lâmina metálica e formato alongado, pode ser confundido com facas ou outros utensílios que pertencem à categoria de talheres.
 - **Falta de amostras específicas:** Se o modelo recebeu poucas imagens de cutelos durante o treinamento, ele pode não distinguir bem esse objeto de outras classes semelhantes.
 - **Ambiguidade em bordas e detalhes:** A forma ou o brilho do metal pode gerar confusão em relação a objetos da categoria "talher".

ANALISANDO O TESTE



1. Panela – 99%

O modelo apresentou alta confiança (99%) de que a imagem contém uma panela. Esse valor indica que as características visuais da panela – como formato arredondado, alças ou superfície metálica – foram bem identificadas.

✓ Interpretação:

O modelo está bem treinado para reconhecer panelas, demonstrando que essa categoria foi amplamente representada durante o processo de aprendizado. A precisão elevada sugere que o modelo reconhece com consistência esse objeto, mesmo em cenários variados.

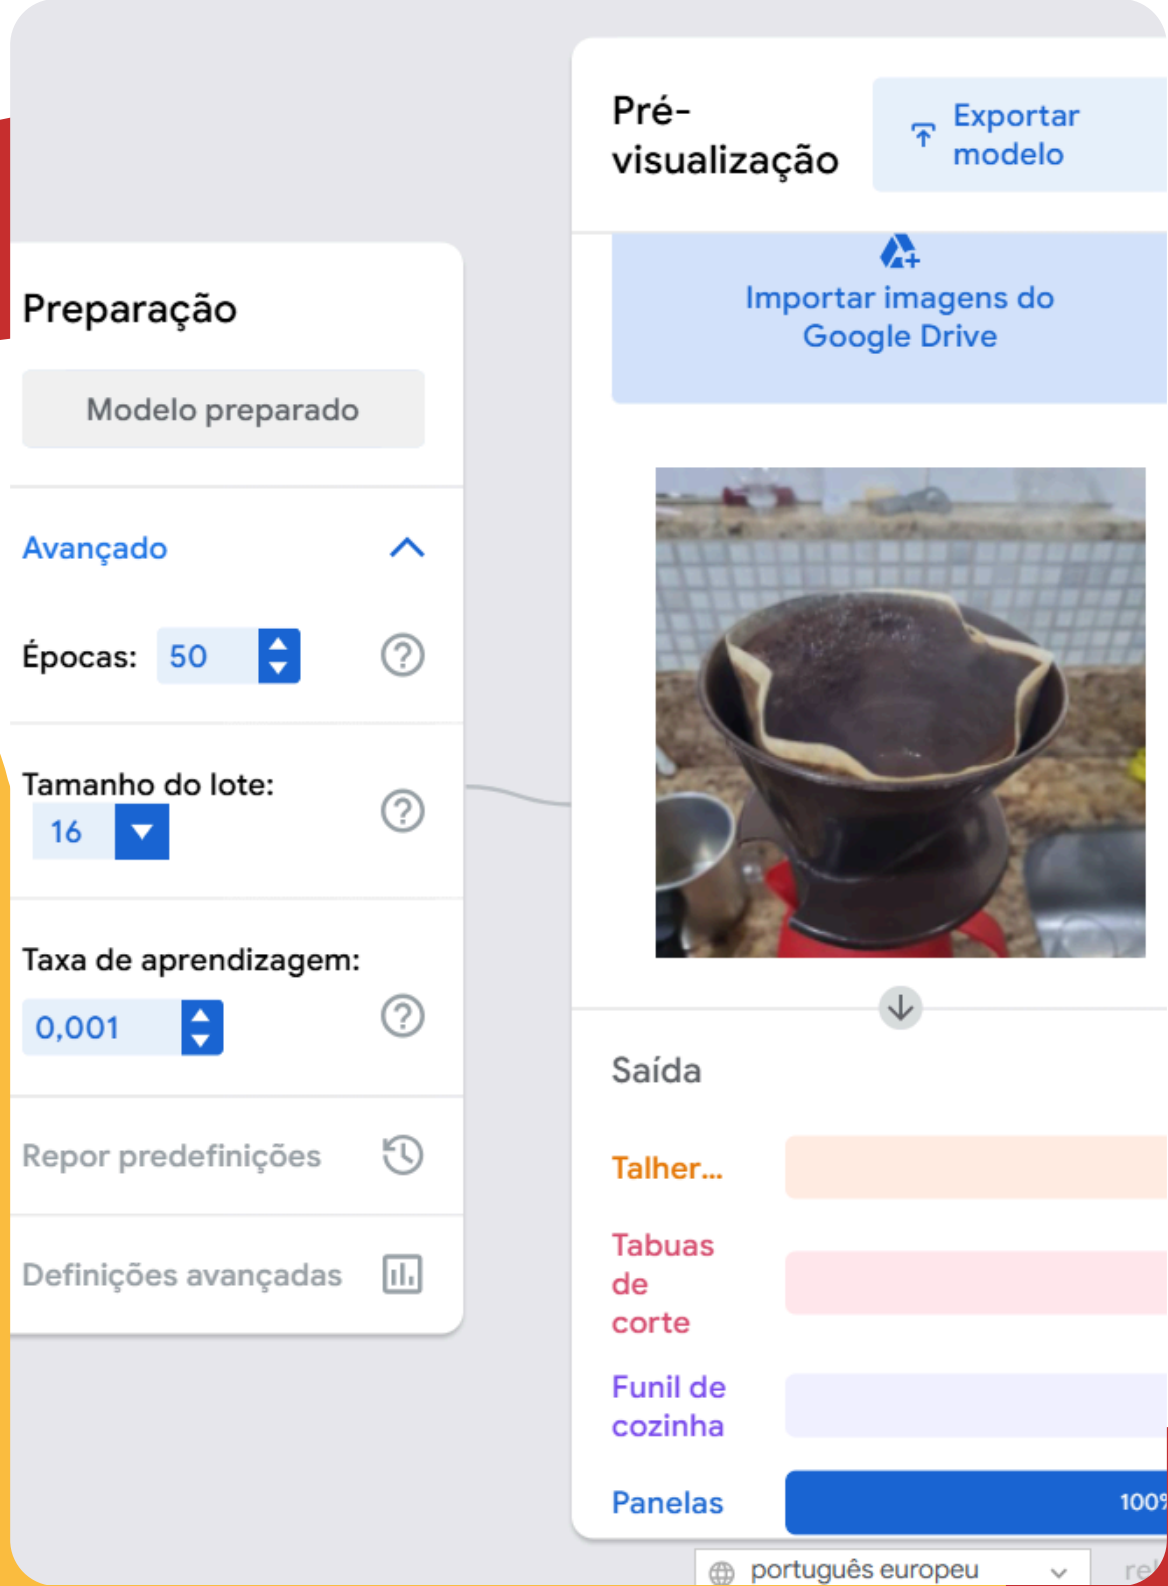
2. Funil – 1%

Apesar de a imagem conter um funil, o modelo atribuiu uma baixa confiança (1%) a essa categoria. Esse pequeno valor indica que o modelo percebeu algumas características visuais mínimas associadas ao funil, mas não teve segurança suficiente para confirmar sua presença.

⚠ Possíveis causas do erro:

- **Diferença de destaque:** A panela provavelmente ocupou a maior parte da imagem ou tinha um contraste mais evidente, fazendo com que o funil fosse menos reconhecível.
- **Falta de variação no treinamento:** Se o modelo não recebeu imagens suficientes de funis em diferentes tamanhos, posições ou iluminações, ele pode ter dificuldade em identificá-los com precisão.
- **Sobreposição de objetos:** Se o funil estava parcialmente oculto ou próximo da panela, o modelo pode ter tido dificuldade em distinguir claramente os dois objetos.

ANALISANDO O TESTE



1. Panela – 100%

O modelo demonstrou uma confiança total (100%) ao identificar a panela na imagem, o que sugere uma forte habilidade de reconhecimento para esse objeto específico. Isso indica que o modelo foi bem treinado para identificar panelas, independentemente da posição ou do contexto na imagem. As características visuais como formato, alças e materiais metálicos provavelmente foram detectadas com alta precisão.

✓ Interpretação:

A confiança de 100% reflete que o modelo está bem calibrado para reconhecer panelas, provavelmente devido à boa representação da categoria durante o treinamento. Esse alto valor sugere que, em cenários semelhantes, o modelo continuará a identificar panelas de forma consistente.

2. Funil – 0%

A confiança atribuída ao funil foi 0%, o que significa que o modelo não conseguiu reconhecer a presença do funil na imagem. Isso pode ser um reflexo de várias limitações no treinamento ou na natureza visual do funil em relação à imagem.

⚠ Possíveis causas do erro:

- **Desempenho visual do funil:** Embora o funil estivesse mais nítido na imagem, o modelo pode não ter sido treinado com exemplos suficientes ou variados dessa categoria. Isso pode ter levado à incapacidade de identificar o funil corretamente.
- **Falta de variação no treinamento:** Se o modelo não recebeu imagens com funis em diversas condições – diferentes tamanhos, ângulos, iluminações ou fundos – ele pode ter dificuldades em reconhecer o objeto quando exposto a novas situações visuais.
- **Características visuais do funil:** O modelo pode ter dificuldade em identificar o funil devido à simplicidade de suas formas e à possível confusão com outros objetos na cena. Mesmo que o funil fosse mais nítido, ele pode não ter se destacado o suficiente para o modelo.
- **Sobreposição de objetos:** Se a panela estava mais proeminente na imagem, ela pode ter ofuscado o funil, levando o modelo a identificar com certeza a panela enquanto ignorava o funil.



RESULTADOS OBTIDOS DO TESTE E AVALIAÇÃO

TESTE REALIZADO COM 50,
IMAGENS DIVERSAS QUE 80%
POSSUIA 2 OU MAIS CATEGORIAS
NA MESMA IMAGEM

ACURÁCIA MÉDIA

acuracia media dos testes é de 49.9%

OBJETIVO

Expor a IA a um cenário onde se tem 2 ou mais
categorias, com um fundo mais proximo da realidade

RESULTADO

Considerando a média da acuracia obtida atraves dos
testes podemos considerar um resultado parcial.

MELHORIAS

1. Equilibrar as categorias:

Se houver uma classe que está sub-representada no treinamento (por exemplo, funil ou cutelo), adicione mais exemplos dessa categoria para que a IA tenha uma chance igual de aprender a reconhecer todos os objetos, evitando que ela favoreça categorias mais frequentes.

3. Aumentar a quantidade de dados de treinamento:

Quanto mais imagens você tiver para cada objeto, melhor será o modelo. A coleta de dados deve ser variada, considerando diferentes cenários e características dos objetos.

2. Ajuste da resolução e qualidade das imagens:

Imagens de alta qualidade e resolução podem ajudar a IA a identificar detalhes mais sutis dos objetos, como texturas e bordas.

4. Adicionar categoria "fundo":

Se o modelo for treinado para distinguir entre objetos e fundos, ele pode aprender a identificar melhor os objetos principais, evitando que eles sejam confundidos com o ambiente ao redor.



FONTES & ALUNOS

FERRAMENTAS

- Teachable Machine
- Notebooklm .google

IMAGENS

- Pixabay
- Freepik
- IStock
- Canvas

FEITO POR:

- Renan Francisco de Paula(rm561454)
- Jonas Luis da Silva(rm561465)
- João Vitor Severo Oliveira(rm566251)



FIAP

OBRIGADO

POR PARTICIPAR!

